ONCFM

Projet 12 : Détectez des faux billets avec R ou Python

OPENCLASSROOMS

1. Les traitements et analyses

a. Analyse des nulls

	0
is_genuine	0
diagonal	0
height_left	0
height_right	0
margin_low	37
margin_up	0
length	0

b. Analyse rapide via .describe après suppression des nulls

Vrai

	diagonal	height_left	height_right	margin_low	margin_up	length
count	971.000000	971.000000	971.000000	971.000000	971.000000	971.000000
mean	171.988476	103.951679	103.809094	4.116097	3.052544	113.203059
std	0.301402	0.301518	0.288862	0.319124	0.185425	0.356123
min	171.040000	103.140000	102.910000	2.980000	2.270000	111.760000
25%	171.790000	103.745000	103.610000	3.905000	2.925000	112.960000
50%	171.990000	103.950000	103.810000	4.110000	3.050000	113.200000
75%	172.200000	104.140000	104.000000	4.340000	3.180000	113.460000
max	172.920000	104.860000	104.950000	5.040000	3.740000	114.320000

Faux

	diagonal	height_left	height_right	margin_low	margin_up	length
count	492.000000	492.000000	492.000000	492.000000	492.000000	492.000000
mean	171.901402	104.188537	104.143272	5.215935	3.351504	111.632114
std	0.305473	0.224418	0.271683	0.553531	0.179343	0.615343
min	171.040000	103.510000	103.430000	3.820000	2.920000	109.490000
25%	171.697500	104.040000	103.950000	4.840000	3.227500	111.200000
50%	171.910000	104.180000	104.160000	5.190000	3.350000	111.630000
75%	172.092500	104.330000	104.320000	5.592500	3.472500	112.030000
max	173.010000	104.880000	104.950000	6.900000	3.910000	113.850000

1. Les traitements et analyses

Vrai Faux

c. Analyse de la distribution et des écarts de valeurs par type de billets

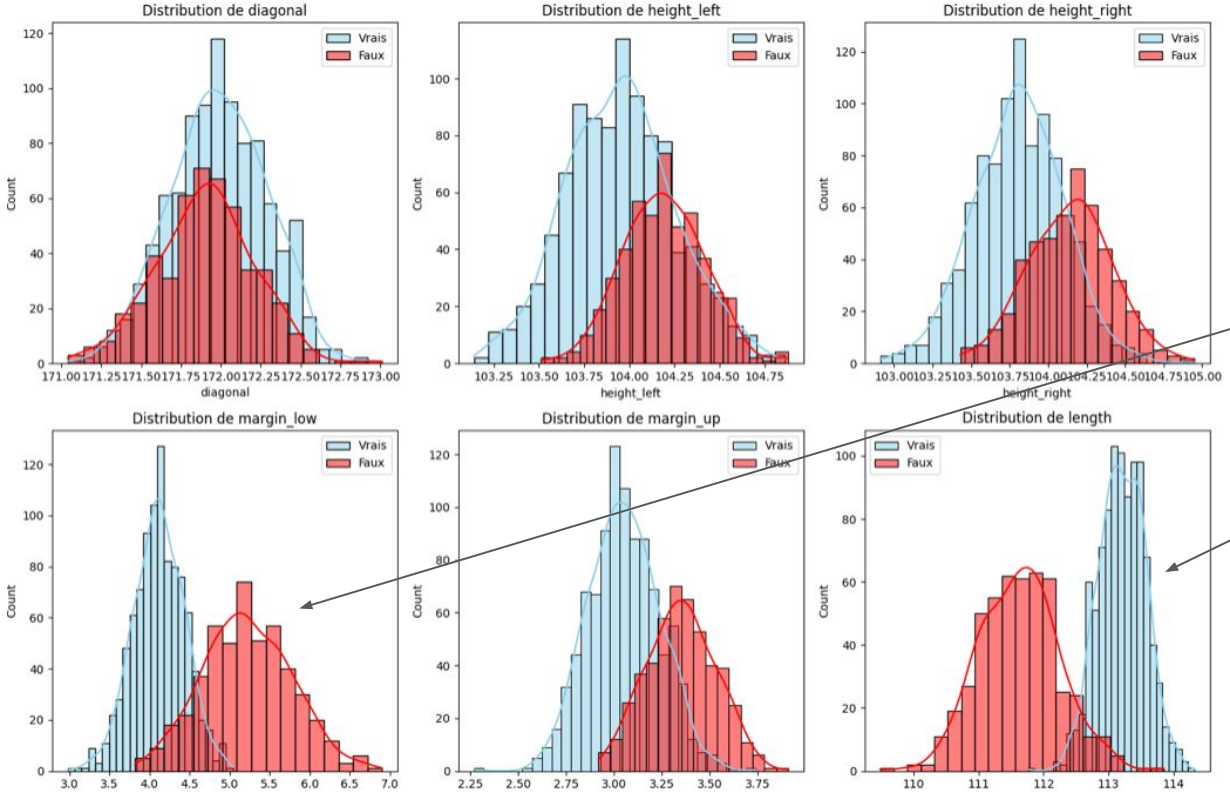

Margin supérieures sur des faux billets notamment margin low

lenght supérieures sur des vrais billets

OPENCLASSROOMS

1. Les traitements et analyses

d. Analyse des données et des écarts via des boîtes à moustaches

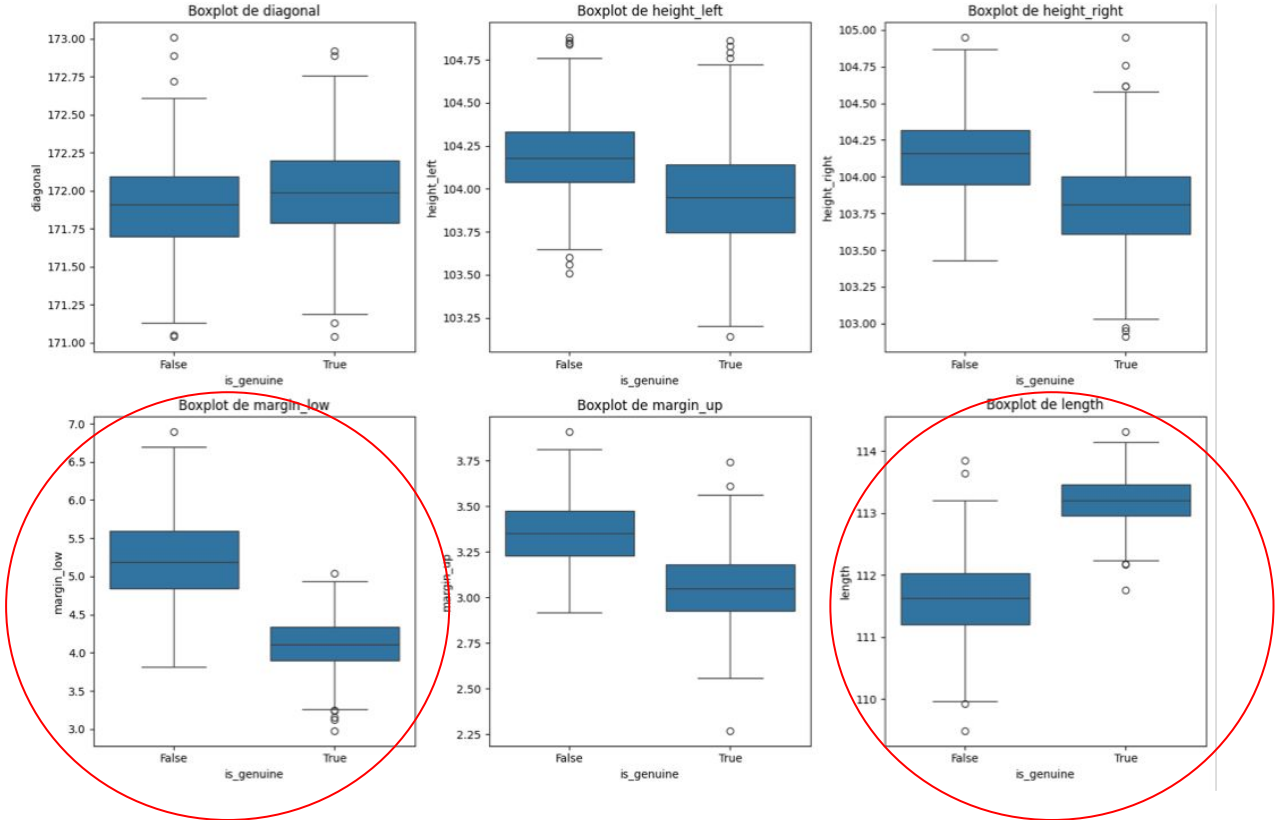

1. Les traitements et analyses

e. Analyse des corrélations entre valeurs

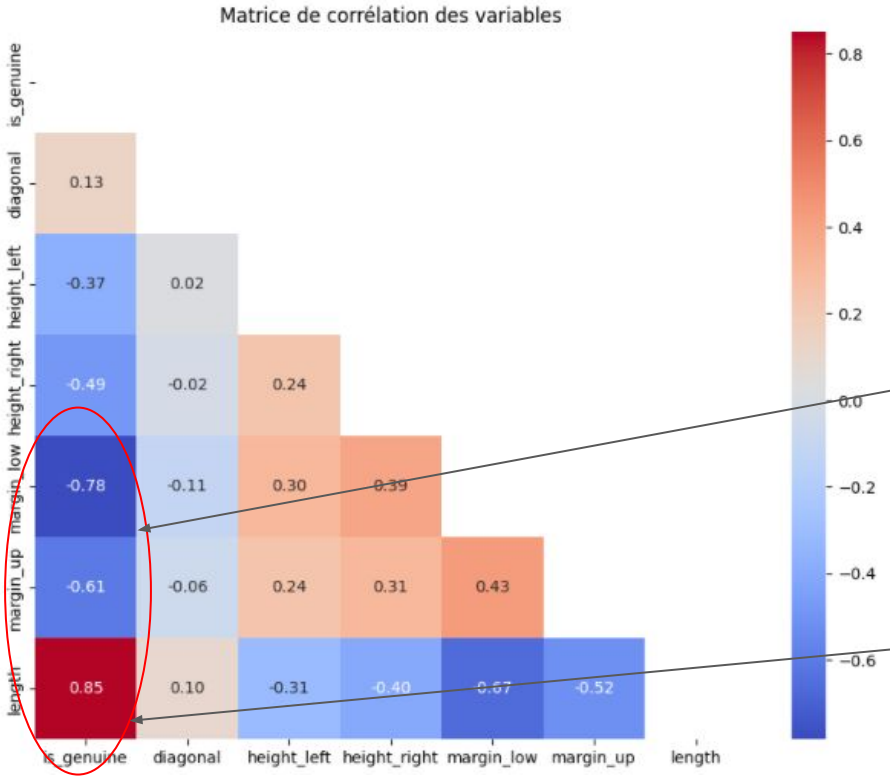

Margin supérieures sur des faux billets notamment margin low

lenght supérieures sur des vrais billets

1. Les traitements et analyses

f. Traitement de la donnée avant modèles

Train test split

Séparation de mes données en 80/20
80 % de données pour entraîner les données
20% pour tester mon modèle sur une partie “inconnue” des données

Scaler / normalisation

Mise à l’échelle des données sur le même ordre de grandeur pour empecher de fausser les modèles

Modèle OLS

Modele statistique qui permet de determiner les variables vraiment utiles en observant leur p value

Coude

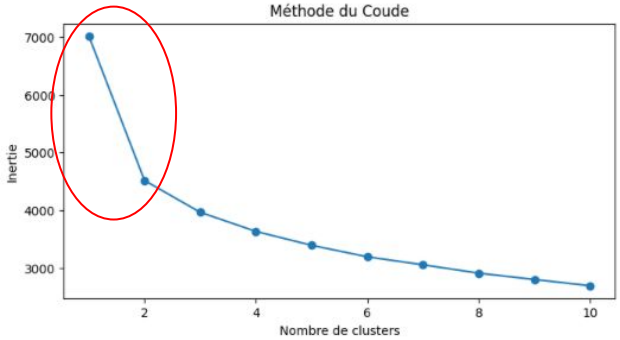

1. Les traitements et analyses

g. Réalisation des groupes et distinction de billets en deux groupes avec le kmeans et l'acp

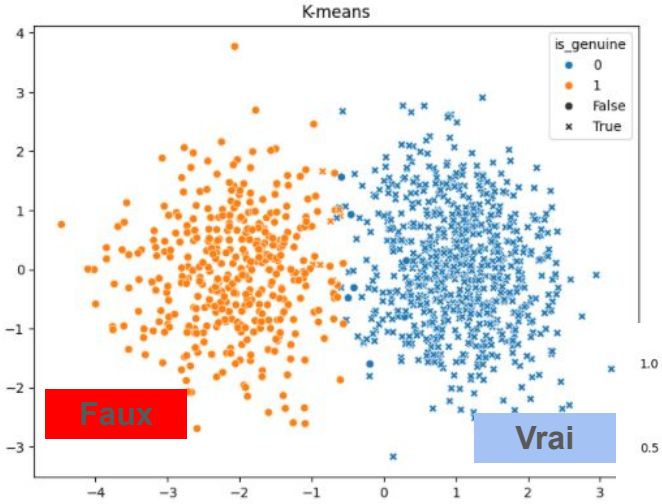

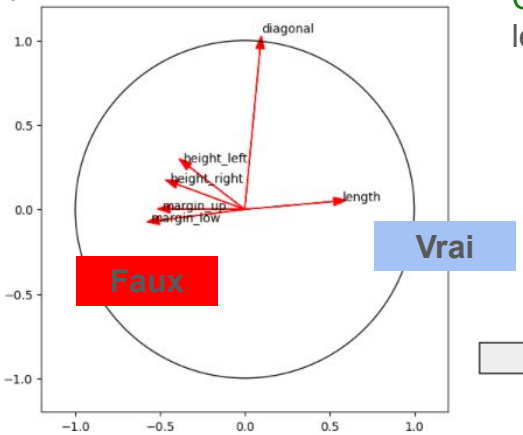

ACP = 6 variables de nos billets en 2 variables qui servent à l'affichage des points

Kmeans = visualisation des points en leur réelle répartition (2 groupes)

Cercle de corrélations = qu'est ce qui défini les vrais des faux

Confirme l'analyse vue sur les histogrammes avant !

OPENCLASSROOMS

2. Algorithmes

KNN

Comparaison avec les 5 billets alentours pour trancher.

98.29%

Kmeans

Séparation des billets en groupes sans connaitre leur nature à l'avance.

97.95%

Random Forest

Probabilités via arbres de décision sur des données connues pour ensuite trancher si les billets sont vrais ou faux.

98.98%

Regression Logistique

Se base sur les billets connus pour établir une limite vrai / faux et donner la probabilité d'un billet d'être d'un coté ou de l'autre.

98.98%

3. Décision

Regression Logistique

+ de transparence sur les resultats

Se base sur les billets connus pour établir une limite vrai / faux et donner la probabilité d'un billet d'être d'un coté ou de l'autre.

98.98%

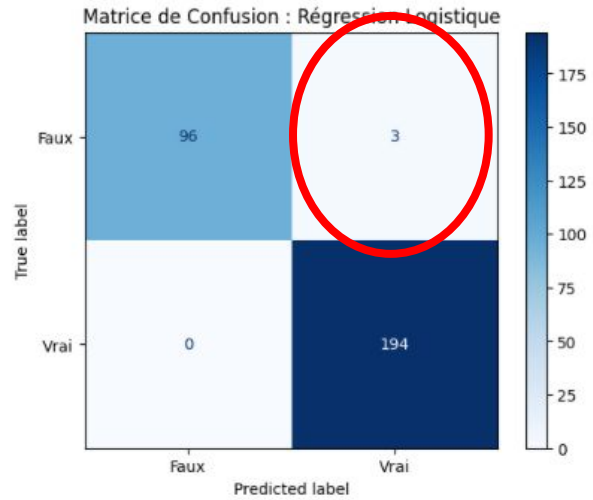

Accuracy : 98.98%

3. Décision

Avec

La Regression Logistique

Bons résultats : 98.98%	Soit 3 erreurs

```
3 erreurs
Erreurs
      diagonal  height_left  height_right  margin_low  margin_up  length
1103    171.88       104.05        103.75        4.41       3.21  112.52
1407    172.02       103.99        104.28        4.22       2.98  112.42
1190    171.45       104.21        104.18        4.55       3.52  113.21

      Ce qui devrait être prédit (le vrai is genuine)  \
1103                                            False
1407                                            False
1190                                            False

      Prédiction avec notre modèle
1103                         True
1407                         True
1190                         True
```

Comme vu dans nos analyses

=> Cela porte le modèle à confusion car des éléments qui d'habitude sont marquants sont peu détectables ici dans ces faux billets qui ont des éléments proches de vrais billets

Margin Low relativement basse
Lenght assez hautes
Comme les vrais billets

OPENCLASSROOMS

4. Application

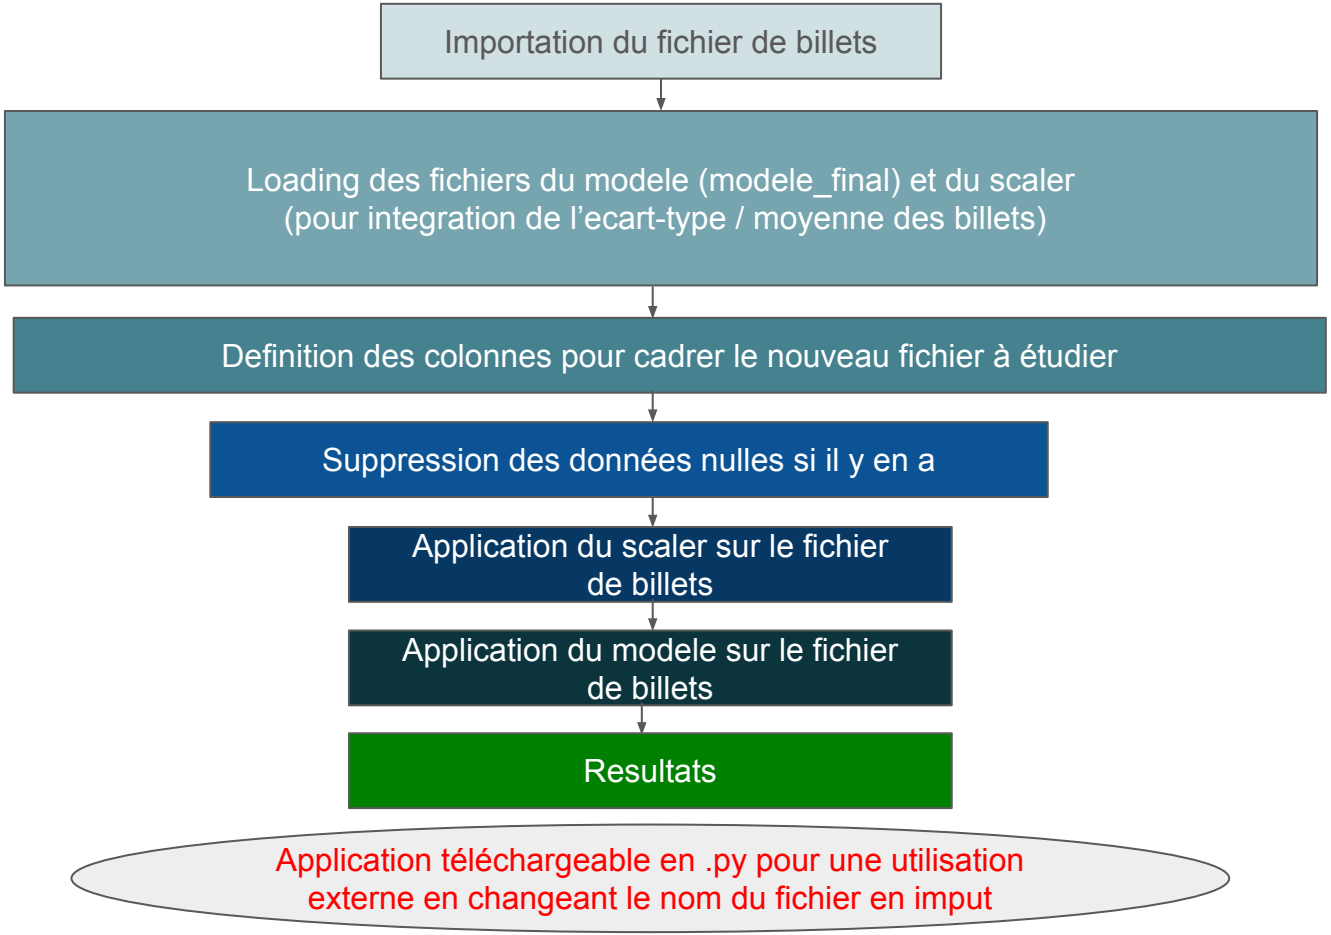

OPENCLASSROOMS